

Testa Fiorella, Rocha Milagros.

Licenciatura en Sistemas.

UCALP.

2025.

Trabajo Final - Lenguajes

Análisis Estadístico Descriptivo del Dataset y Desarrollo de API

1. Introducción

El presente informe tiene como objetivo realizar un análisis estadístico descriptivo basado en los archivos del dataset **TMDB 5000**, que contienen información estructurada sobre miles de películas, su reparto, equipo técnico y características de producción.

El análisis se centra exclusivamente en técnicas descriptivas: limpieza, transformación, métricas básicas y relaciones simples entre variables, sin utilizar modelos predictivos ni machine learning.

Para ello se emplearon las librerías **pandas**, **numpy**, **matplotlib**, **seaborn** y **ast** del lenguaje **Python**, que permitieron estructurar, transformar y visualizar adecuadamente la información.

2. Objetivo General

Desarrollar una comprensión profunda del dataset TMDB, abordando:

- Calidad, estructura y consistencia de los datos.
- Métricas descriptivas claves del conjunto de películas.
- Relación entre presupuesto y rating.
- Evolución de la duración de las películas.
- Relación entre géneros y retorno económico (ROI).
- Interacción entre películas y su reparto/equipo técnico.

- Identificar directores con mejor rating promedio (con mínimo de películas).

3. Descripción de los Archivos

3.1 tmdb_5000_movies.csv

Incluye información detallada de cada película:

- Título, fecha de lanzamiento y año.
- Presupuesto (*budget*) y recaudación (*revenue*).
- Géneros, palabras clave, compañías productoras (en formato JSON).
- Idioma original, popularidad, puntaje promedio (*vote_average*).
- Duración (*runtime*).
- Sinopsis y metadatos adicionales.

3.2 tmdb_5000_credits.csv

Contiene principalmente:

- **cast**: elenco y actores, con datos en formato JSON.
- **crew**: miembros del equipo técnico, indicando rol (Director, Productor, Guionista, etc.).

Ambos archivos se relacionan mediante el campo **movie_id**, lo que permite unificar la información en análisis posteriores.

4. Proceso Metodológico

4.1 Carga de Datos

Se utilizó `pandas.read_csv()` para cargar ambos archivos, manteniendo rutas relativas para asegurar reproducibilidad.

4.2 Inspección Inicial

A través de `head()`, `info()`, `describe()` y conteo de nulos se identificaron errores, tipos incorrectos y estructuras inconsistentes.

4.3 Limpieza y Conversión de Datos

Las correcciones principales fueron:

- **Conversión de columnas JSON expresadas como texto.**

El dataset incluye estructuras JSON guardadas como *strings*, por ejemplo:

```
"[{ 'id': 28, 'name': 'Action' }]"
```

Para convertirlas en **listas y diccionarios reales**, se utilizó:

```
ast.literal_eval()
```

-

Esto permitió iterar géneros, actores y directores como estructuras Python válidas.

- **Normalización de fechas** → tipo `datetime` y extracción del año.
- **Filtrado de valores inconsistentes**
Se eliminaron películas con presupuesto o recaudación igual a 0 porque distorsionan métricas como ROI o rangos de presupuesto.
- **Creación de columnas nuevas:**
 - Año de lanzamiento
 - $ROI = \text{revenue} / \text{budget}$
 - Rango de presupuesto
 - Década de lanzamiento

Análisis Estadístico Descriptivo

A continuación se presentan los ejes evaluados.

5. Análisis 1 — Rentabilidad (ROI) Promedio por Género

Este análisis busca identificar **qué géneros presentan mayor rentabilidad** relativa, utilizando el indicador ROI:

$ROI = \text{revenue} / \text{budget}$

5.1 Metodología

- Se trabajó con las columnas **budget**, **revenue** y **genres** del dataset de películas.
- Se filtraron películas con **budget > 0** y **revenue > 0**, ya que los valores en 0 distorsionan el cálculo del ROI.
- La columna **genres** está almacenada como JSON en texto, por lo que se convirtió a listas/diccionarios con ``ast.literal_eval()`` para poder iterar y extraer los nombres de géneros.
- Después se calculó el **ROI por película** y se obtuvo **el ROI promedio por género**, generando el gráfico “ROI promedio por género” y exportando los resultados a CSV para la API.

5.2 Resultados

En el gráfico se observa que los géneros con **ROI promedio más alto** son:

- * Comedia (el más alto)
- * Drama
- * Horror
- * Thriller

Mientras que la mayoría de los otros géneros presentan ROI promedio considerablemente menor (valores cercanos a 0 en comparación con los primeros).

Un punto importante es que el ROI puede quedar muy influenciado por valores extremos: por ejemplo, películas con presupuestos muy bajos y recaudación alta generan ratios enormes, elevando el promedio del género.

5.3 Conclusión

En el dataset analizado, la rentabilidad relativa **varía fuertemente según el género**. Se destacan comedia y drama como los géneros con mayor ROI promedio, lo cual sugiere que, dentro de TMDB 5000, ciertos géneros tienden a recuperar más la inversión en relación al presupuesto.

6. Análisis 2 — Relación entre Presupuesto y Rating

Este análisis busca determinar si **invertir más dinero en una película se relaciona con obtener mejores calificaciones** por parte del público.

6.1 Metodología

- Se tomaron las columnas **budget** y **vote_average** (rating).
- Solo se incluyeron películas con presupuesto > 0.

- El presupuesto se convirtió a millones de dólares.
- Se crearon **rangos de presupuesto** (bins):
 - 0–10M
 - 10–50M
 - 50–100M
 - 100–200M
 - 200–500M
 - 500M en adelante
- Para cada rango se calculó el **rating promedio**.

6.2 Resultados

El gráfico generado (barplot) muestra:

- Las películas de **bajo presupuesto** (0–10M) suelen tener ratings más estables pero no muy altos.
- Los rangos medios (10–100M) tienden a concentrar películas con **rating promedio ligeramente superior**.
- Los presupuestos extremadamente altos **no garantizan mejores calificaciones**; a veces incluso presentan promedios menores debido al riesgo creativo asociado a grandes producciones.

6.3 Conclusión

No existe una línea ascendente clara que indique que “más presupuesto $\Rightarrow$ mejor rating”. Sin embargo, se observa que:

- ✓ Los presupuestos medios suelen tener mejor recepción.
- ✓ Los extremos (muy bajos o muy altos) muestran mayor variabilidad.

Esto sugiere que el *éxito crítico* no depende directamente de la magnitud del presupuesto.

7. Análisis 3 — Evolución de la Duración de Películas en los Últimos 50 Años

Este análisis examina cómo ha cambiado la **duración típica** de las películas desde 1975 hasta 2010.

7.1 Metodología

- Se filtraron películas entre **1975 y 2010**.
- Se creó la variable **década**, calculada a partir del año de lanzamiento.
Ejemplos:
 - 1993 → 1990
 - 2001 → 2000
- Para cada década se calculó:
 - Duración promedio
 - Duración mediana
 - Cantidad de películas registradas
- Se empleó la **mediana** como indicador principal, ya que la duración puede estar afectada por valores atípicos.

7.2 Resultados

El gráfico de línea muestra:

- En los **años 70 y 80**, las películas tendían a durar entre 95 y 105 minutos.
- Durante los **90 y 2000**, la mediana aumentó ligeramente, llegando a valores entre 110 y 120 minutos.
- En los **2010 y 2020**, la duración media parece estabilizarse o incluso presentar una leve disminución, aunque con mayor dispersión.

7.3 Conclusión

La duración de las películas ha mostrado una **tendencia general a aumentar** entre los años 70 y 2000, seguida de un período de estabilización.

Esto podría deberse a cambios en la industria, como:

- ✓ Mayor presencia de producciones extensas (sagas, superhéroes).
- ✓ Incremento del presupuesto promedio.
- ✓ Preferencia del público por narrativas más desarrolladas.
- ✓ Auge de plataformas que influyen en la duración estándar.

8. Análisis 4 — Directores con Mejor Rating Promedio

Este análisis busca identificar qué directores obtienen **mejor calificación promedio** (vote_average), aplicando un filtro por cantidad mínima de películas para evitar resultados sesgados.

8.1 Metodología

- Se unieron los datasets `movies` y `credits` por el campo **movie_id**, para relacionar películas con su equipo técnico.
- Desde la columna **crew** (JSON en texto) se extrajeron únicamente los registros cuyo rol es **Director** (conversión previa con `ast.literal\_eval()`).
- Se calculó por director:
 - * **rating promedio** (promedio de vote_average)
 - * **cantidad de películas**
- Se filtraron directores con **mínimo 3 películas** (para mejorar la confiabilidad del ranking.)

8.2 Resultados

El gráfico “Top 10 directores por rating promedio” muestra como mejor posicionados a:

- Hayao Miyazaki
- Sergio Leone
- Billy Wilder
- Christopher Nolan
- Pete Docter
- Stanley Kubrick
- Denis Villeneuve
- Miloš Forman
- Frank Capra
- Quentin Tarantino

Las diferencias entre ellos no son enormes, pero se observa un grupo con ratings promedio consistentemente altos (aprox. entre 7.5 y 8).

8.3 Conclusión

Aplicando el filtro de mínimo 3 películas, se logra un ranking más estable (se evitan casos aislados con 1 película muy bien puntuada). En el dataset, los directores del top aparecen con **alta valoración promedio**, lo que sugiere consistencia en la recepción del público.

Como limitación, el resultado depende de cuántas películas de cada director estén incluidas en TMDb 5000 y del sesgo general del dataset.

9. Visualizaciones

Se generaron gráficos utilizando Matplotlib y Seaborn:

- Barras comparativas
- Gráfico de líneas
- Líneas temporales
- Distribuciones por rangos

El diseño se centró en claridad y legibilidad (tema claro, fuentes grandes, etiquetado claro).

10. Reproducibilidad del Proyecto

El análisis es totalmente replicable debido a:

- Uso de rutas relativas
- Código modular
- Comentarios claros
- Exportación a CSV de cada resultado
- Conversión correcta de datos JSON

11. Limitaciones del Dataset

- Muchos presupuestos y recaudaciones son 0 o inconsistentes.
- Algunas estructuras JSON contienen cientos de elementos.
- Años y fechas faltantes.
- Enfoque sesgado al cine estadounidense.

12. Mini-API local (FastAPI) y Dashboard

Como cierre integrador del trabajo, se desarrolló una **mini-API local con FastAPI** para publicar los resultados principales del análisis en formato **JSON** y permitir su descarga en **CSV**, cumpliendo con el requisito de endpoints del enunciado.

La API se implementó en `app.py` y ofrece:

- Una **página principal (dashboard)** en / que muestra los **4 gráficos** y una **vista previa** (primeras filas) de cada resultado exportado. Para esto, el script carga los CSV generados por el notebook y convierte las imágenes PNG a Base64 para incrustarlas en el HTML.
- **Endpoints JSON** con los resultados del análisis:
 - `/api/presupuesto_rating`
 - `/api/duracion_decadas`
 - `/api/roi_genero`
 - `/api/directores_rating`
- **Endpoints de descarga** de los archivos CSV correspondientes:
 - `/descargar/presupuesto_rating`
 - `/descargar/duracion_decadas`
 - `/descargar/roi_genero`
 - `/descargar/directores_rating`

Esta conexión entre notebook + API permite que el análisis genere archivos resumidos (CSV/PNG) y que la mini-API los exponga para consulta y demostración en el video.

13. Conclusiones

El análisis descriptivo permitió comprender el comportamiento de las películas registradas en TMDB en términos de rating, presupuesto, duración, géneros y directores.

Se observa que:

- El presupuesto **no determina** directamente la calidad percibida.
- La duración de las películas ha mostrado **tendencias temporales claras**.
- Algunos géneros presentan altos niveles de **rentabilidad relativa**.

- La conversión adecuada de datos estructurados (JSON como texto) es crucial para análisis correctos.

Bibliografía:

Dataset

- Kaggle. *TMDB 5000 Movie Dataset (tmdb-movie-metadata)*.
- The Movie Database (TMDb). *TMDb API Documentation*.

Librerías / herramientas

- FastAPI. *Documentación oficial*.
- Uvicorn. *Documentación oficial*.
- pandas. *Documentación oficial*.
- NumPy. *Documentación oficial*.
- Matplotlib. *Documentación oficial*.
- seaborn. *Documentación oficial*.
- Python (módulo `ast`). *Documentación oficial*.